

THY SENIOR AI ENGINEER CASE STUDY



Cabin Knowledge Assistant

Özel dokümanlar için güvenli, kaynak gösteren ve ölçeklenebilir Agentic RAG

PDF · DOCX · PPTX

LangGraph

Qdrant

OpenAI

Hazırlayan

Sefa İşci

13 Temmuz 2026

Değerlendirme problemini nasıl ele aldım?

Hedef yalnız çalışan bir chatbot değil; doğrulanabilir ve büyüyebilir bir doküman zekâsı ürünüydü.

İş ihtiyacı

- Kullanıcı kendi dokümanını yükleyebilmeli
- Birden fazla kaynaktan soru sorabilmeli
- Cevabın dayanağını görebilmeli
- Büyük belgelerde performans korunmalı
- Gelecekte binlerce dokümana ölçeklenmeli

Çalışan çözüm



3 format

PDF, Word ve PowerPoint



2 ingestion yolu

Semantic ve Docling fixed



Hybrid retrieval

Dense + sparse + reranking



Kaynak güveni

Citation, grounding ve no-answer


POC sonucu

Çalışıyor

Üretim için kimlik, dayanıklı işler ve gözlemlenebilirlik tamamlanmalı.

Sistem mimarisi: tek güven sınırı, iki veri deposu

Browser iç kullanıcı kimliğini belirlemez; tenant sınırı FastAPI tarafından kurulur.



ASYNCR I/O

Chat oturumları paralel; aynı oturumdaki mesaj sırası kilitli. Ingestion sınırları ayrı ayrı ayarlanabilir.

Kullandığım teknoloji yığını ve async sınırlar

Bileşenleri kullanım amacına göre ayırdım; model çağrılarını ve kalıcı veriyi birbirine karıştırmadım.



Experience

React 19

TypeScript

Vite

TanStack Query

Zustand

KaTeX



Application

FastAPI

Pydantic v2

SQLAlchemy
async

Alembic

Nginx



AI / Retrieval

LangGraph

OpenAI
Responses

OpenAI
Embeddings

Qdrant

Stable-hash sparse

BM25-ready



Document AI

Docling

PyMuPDF

LibreOffice

RapidOCR

python-docx

python-pptx



Runtime

PostgreSQL 16


Docker
Compose

Structured logs

Versioned pricing

Ingestion ve OCR: her sayfayı eksiksiz işle, doğru yolu seç

İki ingestion yolu birbirinden bağımsızdır ve ayrı Qdrant collection'larına yazar.



4 ASYNC JOB

Backend varsayılını: 4 eşzamanlı ingestion işi · sayfa ve batch limitleri ayrıca kontrol edilir.




RAG akışı: yüksek recall, kontrollü context

Retrieval recall'ı geniş aday havuzuyla; answer accuracy'yi reranking ve grounding kapıları ile koruyorum.



LangGraph: retrieval ve answer subgraph'ları

Graph açık, sınırlı ve test edilebilir; başarısız provider çağrısı belge yetersizliği gibi gösterilmez.



Güven, kalite ve operasyonel görünürlük

Citation bir UI özelliği değil; retrieval'dan final response'a kadar korunan bir veri sözleşmesidir.



Isolation

- Backend-resolved user UUID
- Qdrant user + document filter
- Cross-user payload recheck



Grounding

- Opaque evidence IDs
- Exact citation validation
- Claim-level reflection + one repair



Operations

- Usage and versioned cost
- Recall@K · MRR · no-answer
- OpenTelemetry production target

319

Python testi

32

frontend testi

0

unauthorized chunk
hedefi

1

bounded repair

Fail closed



Model geliştirme stratejisi: önce RAG, sonra ölçülebilir tuning

2.000 şirket dokümanı model ağırlıklarına değil retrieval katmanına aittir.

Veri varlıkları

2.000 şirket dokümanı

5.000 soru-cevap

Geri bildirim

PII temizliği, izin, deduplication ve insan kontrolü olmadan eğitim verisine dönüşmez.

01 Prompt + retrieval İlk iyileştirme alanı. Golden set ile retrieval ve cevap hatasını ayır.

02 SFT Tekrarlayan format, intent ve tool-use davranışı için koşullu.

03 RFT Citation, groundedness, no-answer ve kapsam için güvenilir grader varsa daha anlamlı.

04 Open-source pilot TRL + GRPO/RLOO; LoRA/QLoRA ve vLLM ile maliyet/kalite karşılaştırması.

KARAR

RFT retrieval recall'ı tek başına çözmez; doğru evidence kullanma ve cevaplama davranışını geliştirir.



Altı aylık yol haritası ve sonuç

Önce güvenli ve ölçülebilir temel; sonra kalite ve ölçek; en son model ekonomisi.

01

Hafta 1-8

Güvenli pilot

- OIDC / Entra ID
- Dayanıklı ingestion kuyruğu
- OpenTelemetry başlangıcı
- THY evaluation set v1

02

Hafta 9-16

Kalite ve ölçek

- OCR / vision routing
- Model router shadow mode
- Streaming + feedback
- Load ve retrieval testleri

03

Hafta 17-24

Enterprise pilot

- Açık kaynak model pilotu
- Backup / restore ve DR
- Tenant quota ve rollout
- TCO + kalite kararı